TEST_03

- **Guide**
- **1. Data Wrangling Problem**
- **2. Visualization Problem(Using ggplot2)**

- 필요 패키지 : `dplyr` , `tidyr` , `ggplot2`
- 필요 데이터 : `Tour_age.csv` , `Tour_gender.csv` , `Tour_purpose.csv`

Guide

- 시험시간 : 13:30 ~ 15:00 (총90분)
- R markdown을 이용하여 생성한 html파일 모두 제출
- Dropbox에 제출시 html 파일과 rmd 파일 모두 업로드 해야함
  - 공유된 폴더안에 시험날짜 폴더를 만들고 (예 : `202101234`)
  - 관련 데이터는 `Data폴더` 를 만들어 제출
  - html,rmd파일은 `Rmd폴더` 에 학번_이름으로 작성 제출 (예 : 202101234_홍길동)
- 문제에서 주어진 결과와 같게 작성
  - ex) 작성방식 : 1.1번 문제라고 적고 R Chunk를 생성하여 그 안에 해당 code 기입
- 업로드 및 수정시간이 모두 기록 됨에 유의
- 코드공유 적발시 0점 처리
- 문제에서 출력한대로 출력(전체데이터 출력은 지양)
- **위의 유의사항을 어길 시 감점**
- **시험시간을 넘겨서 제출하면 0점 처리**

0. Packages

```
library(dplyr)
library(tidyr)
library(ggplot2)
```

1. Data Wrangling Problem

1.1 데이터를 불러와서 다음과 같이 출력하시오.[10점]

- 데이터를 불러와서 각각 age, gender, purpose로 저장하시오[5점]
- 하나의 데이터 프레임으로 만든 후 다음과 같이 필요한 열만 가져오시오[5점]
    - 반드시 결과물과 같이 출력되도록 할 것(필요한 열만 잘 선택할 것)
- head()로 출력할 것

```
age <- read.csv(file = "../Data/Tour_age.csv")
gender <- read.csv(file = "../Data/Tour_gender.csv")
purpose <- read.csv(file = "../Data/Tour_purpose.csv")


tour <- cbind(age %>% select(-c(4:5)), gender %>% select(-c(1:5)), purpose
%>% select(-c(1:5)))

head(tour)
```

```
##     date      nation visitor age0.20 age21.30 age31.40 age41.50 age51.6
0 age61
## 1 2019-1       China  392814   36520   108591   103657    48574    4089
3 40998
## 2 2019-1       Japan  206526   18015    57921    34165    39811    3385
7 20330
## 3 2019-1      Taiwan   87954   18888    17927    18595    18862     816
9  4566
## 4 2019-1   Hong Kong   35896    3890    11384     7400     5461     462
9  2137
## 5 2019-1       Macao    2570     223     1013      762      264      18
1    92
## 6 2019-1 Phillipines   30473    1436     5051     5486     3140     183
1   811
##     male female crewman tourism business official.affairs studying othe
rs
## 1 147511 231722   13581  320113     2993              138     8793  607
77
## 2  75070 129029    2427  198805     2233              127      785   45
76
## 3  30805  56202     947   86393       74               22      180   12
85
## 4  12172  22729     995   34653       59                2       90   10
92
## 5    748   1787      35    2506        2                0       17
45
## 6  10460   7295   12718   14279      211              161      184  156
38
```

1.2 다음과 같이 변수 명을 변경 후 str()을 통해 출력하시오[15점]

- 다음과 같이 열 이름을 변경하시오[5점]
  - 힌트: age로 시작하는 열들의 이름을 살펴볼 것
- date에서 19년도 5월부터 20년도 4월까지만 filtering해서 가져오시오.[5점]
- date는 factor로 나타낼 것.[5점]
  - 힌트: factor의 levels를 변경할 것, labels는 변경할 필요 없음
- 최종 데이터만 str()로 출력할 것

```
tour = tour %>% rename("age0~20"=age0.20,"age21~30"=age21.30, "age31~40"=a
ge31.40, "age41~50"=age41.50, "age51~60"=age51.60)

tour = tour %>% filter(!date %in% c("2019-1","2019-2","2019-3","2019-4"))

tour$date = factor(tour$date, levels = c("2019-5","2019-6","2019-7","2019-
8","2019-9","2019-10",
                                         "2019-11","2019-12","2020-1","202
0-2","2020-3","2020-4"))
str(tour)
```

```
## 'data.frame':    720 obs. of  17 variables:
##  $ date            : Factor w/ 12 levels "2019-5","2019-6",..: 1 1 1 1
1 1 1 1 1 1 ...
##  $ nation          : chr  "China" "Japan" "Taiwan" "Hong Kong" ...
##  $ visitor         : int  500413 286273 101779 57026 2909 50569 18936 5
2660 44416 13858 ...
##  $ age0~20         : int  17011 20144 10262 5934 182 5084 1662 4348 433
1 539 ...
##  $ age21~30        : int  138797 71069 21375 13256 924 6991 3677 15554
10596 1892 ...
##  $ age31~40        : int  141104 47535 25044 10654 853 7129 3053 12607
10812 2822 ...
##  $ age41~50        : int  66171 51611 18819 9285 368 5841 2189 7457 607
1 1716 ...
##  $ age51~60        : int  63504 47821 13791 10340 365 3647 1472 4588 48
13 823 ...
##  $ age61           : int  58996 45462 11481 6612 216 2491 1001 2623 243
1 431 ...
##  $ male            : int  187922 104270 32707 17219 758 14645 6964 1471
4 19493 6498 ...
##  $ female          : int  297661 179372 68065 38862 2150 16538 6090 324
63 19561 1725 ...
##  $ crewman         : int  14830 2631 1007 945 1 19386 5882 5483 5362 56
35 ...
##  $ tourism         : int  413949 279174 100004 55756 2885 29015 11464 4
5671 32528 4483 ...
##  $ business        : int  4034 2019 84 56 1 201 154 61 1073 2896 ...
##  $ official.affairs: int  534 91 11 2 0 176 152 445 368 99 ...
##  $ studying        : int  14003 715 234 147 13 56 75 71 2338 92 ...
##  $ others          : int  67893 4274 1446 1065 10 21121 7091 6412 8109
6288 ...
```

1.3 월별 총 외국인 방문객 수를 구하시오. [10점]

```
tour %>% group_by(date) %>% summarise(total = sum(visitor))
```

```
## # A tibble: 12 x 2
##    date      total
##    <fct>     <int>
##  1 2019-5  1485684
##  2 2019-6  1476218
##  3 2019-7  1448067
##  4 2019-8  1586299
##  5 2019-9  1459664
##  6 2019-10 1656195
##  7 2019-11 1456429
##  8 2019-12 1456888
##  9 2020-1  1272708
## 10 2020-2   685212
## 11 2020-3    83497
## 12 2020-4    29415
```

1.4 월별, 나이 구간별 외국인 방문객 수를 구하시오. [20점]

- age로 시작하는 열을 gather를 활용해서 long format으로 바꾸시오.[10점]
- 새롭게 생성된 변수를 활용하여 월별, 나이 구간별 방문객 수를 구하시오. [5점]
- 그룹별 상위 2개만 구하시오. [5점]

```
tour %>% gather(age, count, starts_with("age")) %>% group_by(date, age) %
>% summarise(total = sum(count)) %>% top_n(2)
```

```
## # A tibble: 24 x 3
## # Groups:   date [12]
##    date   age       total
##    <fct>  <chr>     <int>
##  1 2019-5 age21~30 355340
##  2 2019-5 age31~40 330804
##  3 2019-6 age21~30 366645
##  4 2019-6 age31~40 321241
##  5 2019-7 age21~30 338386
##  6 2019-7 age31~40 294658
##  7 2019-8 age21~30 388519
##  8 2019-8 age31~40 306222
##  9 2019-9 age21~30 395973
## 10 2019-9 age31~40 334089
## # ... with 14 more rows
```

2. Visualization Problem(Using ggplot2)

2.1 국가별 방문객 수 추이를 그리시오 [25점]

- “China”,“Japan”,“USA”,“Vietnam”,“Russia”에 해당되는 국가만 filtering 하시오.[5점]
- 기본 그림[5점]
- 국가별로 그림을 따로 나타내시오[5점]
- x축 label을 그림과 같이 일부만 표시되게 하시오.[5점]
  - 2019-6, 2019-9, 2019-12, 2020-3만 표시되게 하시오
- x축 label을 45도 기울이시오.[5점]

```
tour %>% filter(nation %in% c("China","Japan","USA","Vietnam","Russia")) %
>% ggplot(aes(date, visitor, fill=nation))+geom_bar(stat="identity") + fac
et_grid(~nation) +scale_x_discrete(breaks=c("2019-6","2019-9","2019-12","2
020-3")) + theme(axis.text.x = element_text(angle = 45, hjust=1))
```

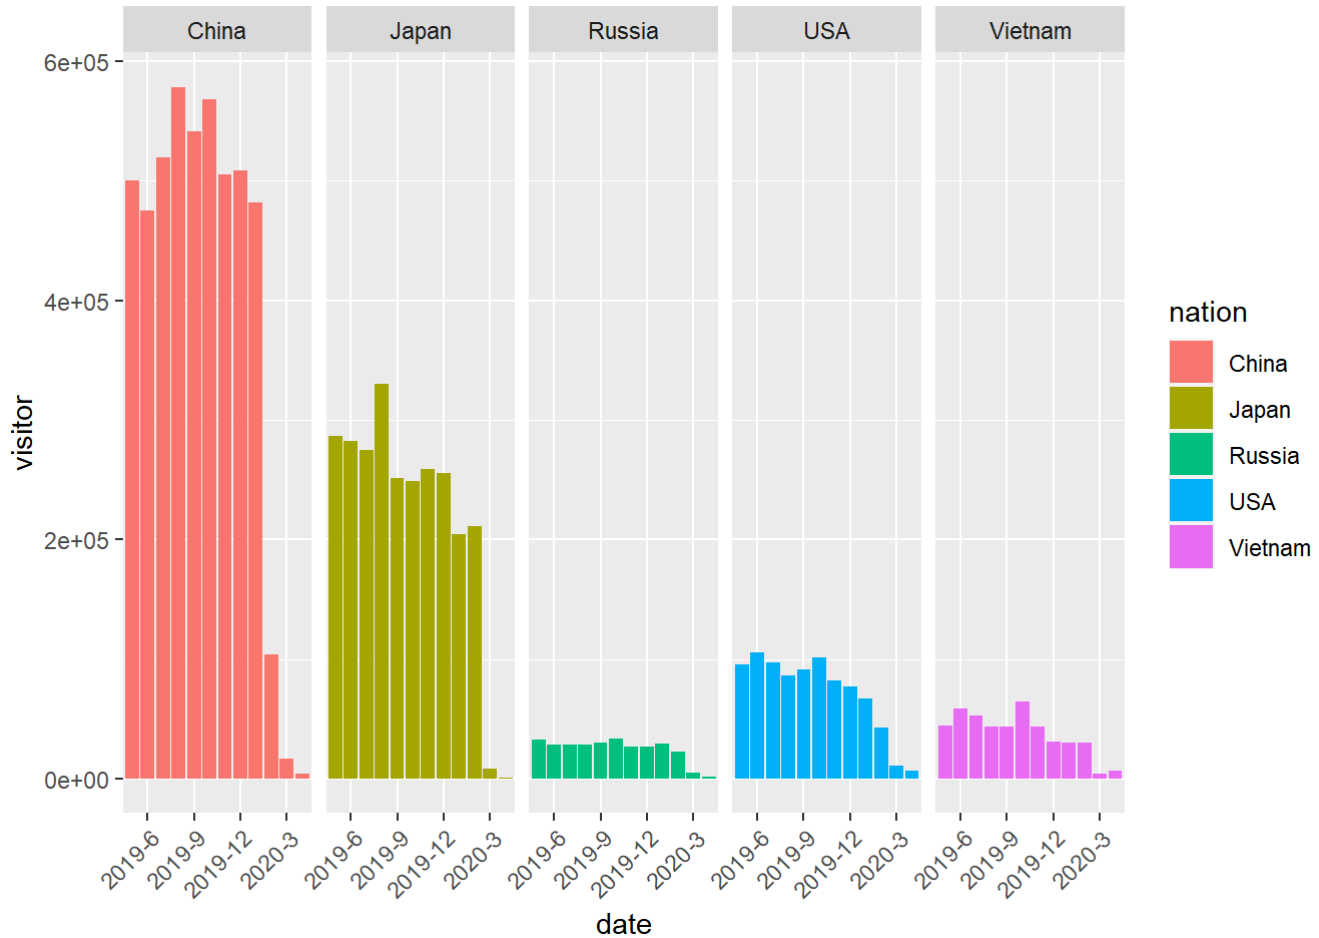

2.2 방문 목적의 변화를 월별로 그리시오 [20점]

- 방문 목적 5가지를 gather를 활용해서 long format으로 바꾸시오.[5점]

    - 방문 목적: tourism, business, official.affairs, studying, others
- 월별, 방문 목적별 방문객 수를 구하고 head()를 통해서 10개만 나타낼 것.[5점]
- 기본 그림[10점]
    - 선이 제대로 안그려지면 부분점수 없음

```
data <- tour %>% gather(purpose, visitors, c(tourism, business, official.a
ffairs, studying, others)) %>% group_by(date, purpose) %>% summarise(visit
ors = sum(visitors))

data %>% head(10)
```

```
## # A tibble: 10 x 3
## # Groups:   date [2]
##    date   purpose          visitors
##    <fct>  <chr>               <int>
##  1 2019-5 business            15020
##  2 2019-5 official.affairs     6457
##  3 2019-5 others             209943
##  4 2019-5 studying            20702
##  5 2019-5 tourism           1233562
##  6 2019-6 business            15006
##  7 2019-6 official.affairs     7327
##  8 2019-6 others             192227
##  9 2019-6 studying            23818
## 10 2019-6 tourism           1237840
```

```
data %>% ggplot(aes(date, visitors, group=purpose,col=purpose))+geom_point
(stat="identity") +geom_line()
```